

Πανεπιστήμιο Μακεδονίας

Τμήμα Εφαρμοσμένης Πληροφορικής

Έτος: 2025-2026

Μάθημα: Μηχανική Μάθηση

Φοιτητές:

- Όμηρος Λούπης – iis23088
- Γιώργος Γουργιώτης – ics23046

Ημερομηνία: 14/01/2026

ΠΙΝΑΚΑΣ ΠΕΡΙΕΧΟΜΕΝΩΝ

1. Εισαγωγή
2. Μεθοδολογία & Προεπεξεργασία
3. Μοντέλα & Υπερπαράμετροι
4. Πειραματικά Αποτελέσματα
5. Ερμηνεία Μοντέλα (Explainability)
6. Συμπεράσματα & Περιορισμοί
7. Βιβλιογραφία

ΚΑΤΑΛΟΓΟΣ ΕΙΚΟΝΩΝ

1. Εικόνα Α: Distribution of Target (σελ. 5)
2. Εικόνα Β: Actual vs Predicted values για το μοντέλο Gaussian Process (σελ. 9)
3. Εικόνα Γ: Actual vs predicted values Random Forest (σελ. 10)
4. Εικόνα Δ: Συγκριτικό Διάγραμμα (σελ. 11)
5. Εικόνα Ε: Shap Summary Plot (σελ. 12)
6. Εικόνα Ζ: Waterfall Plot (σελ. 13)

1. Εισαγωγή

Σκοπός της παρούσας εργασίας είναι η ανάπτυξη και συγκριτική αξιολόγηση μοντέλων μηχανικής μάθησης για την επίλυση ενός προβλήματος παλινδρόμησης (regression). Συγκεκριμένα, καλούμαστε να προβλέψουμε την ποσοτική εξέλιξη της νόσου του διαβήτη σε ασθενείς μετά από ένα έτος, βάσει κλινικών και δημογραφικών χαρακτηριστικών.

Το dataset που χρησιμοποιήθηκε είναι το diabetes της βιβλιοθήκης scikit-learn. Αποτελείται από 442 δείγματα ασθενών, καθένα από τα οποία χαρακτηρίζεται από 10 μεταβλητές εισόδου (features): ηλικία, φύλο, δείκτη μάζας σώματος (BMI), μέση αρτηριακή πίεση (BP) και έξι μετρήσεις ορού αίματος (s1-s6). Η μεταβλητή στόχος (target) είναι μια συνεχής αριθμητική τιμή που υποδηλώνει την εξέλιξη της νόσου.

1.1 Σχετική Βιβλιογραφία

Το συγκεκριμένο σύνολο δεδομένων (Diabetes Dataset) εισήχθη αρχικά από τους Efron et al. (2004) στην εργασία τους για την τεχνική "Least Angle Regression". Αποτελεί ένα πρότυπο benchmark για προβλήματα παλινδρόμησης στην ιατρική πληροφορική λόγω της δυσκολίας πρόβλεψης που παρουσιάζει, εξαιτίας της πολυπλοκότητας των βιοχημικών δεικτών.

Στη διεθνή βιβλιογραφία, τα γραμμικά μοντέλα (Linear Regression) αποδίδουν συνήθως ένα σφάλμα RMSE κοντά στο 54-55. Πιο σύγχρονες προσεγγίσεις που χρησιμοποιούν τεχνικές Regularization (Lasso, Ridge) ή μη γραμμικές μεθόδους (όπως τα Gradient Boosting Trees) προσπαθούν να μειώσουν το σφάλμα περαιτέρω, ωστόσο η βελτίωση είναι συχνά οριακή λόγω του ενδογενούς θορύβου των δεδομένων. Η επίδοση του προτεινόμενου μοντέλου μας (Gaussian Process) κινείται στα ίδια επίπεδα με τη βιβλιογραφία (RMSE ~54.7), επιβεβαιώνοντας την εγκυρότητα της προσέγγισης.

Μεθοδολογία & Προεπεξεργασία

2.1 Περιγραφή Dataset


Τα δεδομένα αποτελούνται από 442 εγγραφές ασθενών. Κάθε εγγραφή περιλαμβάνει 10 χαρακτηριστικά εισόδου (Features):

Δημογραφικά: Ηλικία (age), Φύλο (sex).

Σωματομετρικά: Δείκτης Μάζας Σώματος (bmi), Μέση Αρτηριακή Πίεση (bp).

Βιοχημικά: Έξι μετρήσεις ορού αίματος (s1, s2, s3, s4, s5, s6).

Η μεταβλητή στόχος (Target) είναι μια ποσοτική μέτρηση της εξέλιξης της νόσου ένα έτος μετά την αρχική καταγραφή. Η κατανομή της μεταβλητής στόχου παρουσιάζεται στο ιστόγραμμα της Εικόνας Α.



Εικόνα A: Κατανομή συχνοτήτων της μεταβλητής στόχου (εξέλιξη ασθένειας).

Παρατηρούμε ότι η κατανομή δεν είναι απόλυτα κανονική, παρουσιάζοντας μια ελαφριά λοξότητα (skewness), γεγονός που δικαιολογεί την ανάγκη για προσεκτική κανονικοποίηση και επιλογή μη γραμμικών μοντέλων.

2.2 Διαχείριση Δεδομένων

Για την εξασφάλιση της ποιότητας των δεδομένων, ακολουθήθηκαν τα εξής βήματα:

- Έλεγχος Ελλειπουσών Τιμών: Πραγματοποιήθηκε έλεγχος για κενές τιμές (NaN). Όπως ορίζουν οι καλές πρακτικές, εφαρμόστηκε αφαίρεση των αντίστοιχων εγγραφών (dropna), ώστε να μην επηρεαστεί η εκπαίδευση.
- Κανονικοποίηση (Normalization): Εφαρμόστηκε η τεχνική MinMaxScaling για να κλιμακωθούν όλα τα χαρακτηριστικά στο εύρος $[0, 1]$. Η διαδικασία αυτή

κρίθηκε απαραίτητη διότι αλγόριθμοι όπως τα Gaussian Processes και τα SVR είναι ευαίσθητοι στη διαφορετική κλίμακα των χαρακτηριστικών.

- Σημαντική Σημείωση: Η κανονικοποίηση έγινε αυστηρά εντός του βρόχου επαναλήψεων (fit στο training set, transform στο test set) για την αποφυγή διαρροής δεδομένων (data leakage).

2.3 Διαδικασία Επικύρωσης (Validation)

Για την αξιόπιστη εκτίμηση της απόδοσης, χρησιμοποιήθηκε η τεχνική 6-Fold Cross Validation. Το dataset χωρίστηκε σε 6 ίσα μέρη, όπου σε κάθε επανάληψη το μοντέλο εκπαιδεύονταν στο 83% των δεδομένων (training set) και αξιολογούνταν στο υπόλοιπο 17% (test set). Χρησιμοποιήθηκε σταθερό random_seed=42 για την επαναληψιμότητα των πειραμάτων.

3. Μοντέλα & Υπερπαράμετροι

- Gaussian Process: Καθώς ήταν το μοντέλο με την καλύτερη απόδοση, δώσαμε έμφαση στην επιλογή του Kernel. Καταλήξαμε σε έναν συνδυασμό RBF (για να πιάσουμε τη μη γραμμικότητα) και WhiteKernel, ο οποίος βοήθησε σημαντικά στη διαχείριση του θορύβου που έχει το dataset. Επίσης, ρυθμίσαμε την παράμετρο alpha για καλύτερη κανονικοποίηση.
- Random Forest: Εδώ ο στόχος ήταν να αποφύγουμε το overfitting. Γι' αυτό πειραματιστήκαμε κυρίως με τον αριθμό των δέντρων (n_estimators) και το μέγιστο βάθος τους (max_depth), αλλά και με το πόσα δείγματα

χρειάζονται για να "σπάσει" ένας κόμβος (min_samples_split).

- SVR (Support Vector Regression): Ρυθμίσαμε τις παραμέτρους C και epsilon, που ελέγχουν πόσο αυστηρό είναι το μοντέλο με τα λάθη. Παράλληλα, δοκιμάσαμε διαφορετικούς πυρήνες (kernels), με τον RBF να δείχνει τελικά την καλύτερη συμπεριφορά.
- Gradient Boosting: Βασική μας έγνοια ήταν το learning_rate, δηλαδή το πόσο γρήγορα μαθαίνει το μοντέλο από τα λάθη του, σε συνδυασμό με το πλήθος και το βάθος των δέντρων, ώστε να πετύχουμε ισορροπία ανάμεσα στην ακρίβεια και τη γενίκευση.

Πειραματικά Αποτελέσματα

4.1 Συγκριτικός Πίνακας


Τα αποτελέσματα που παρουσιάζονται είναι ο μέσος όρος των μετρήσεων από τα 6 folds, εξασφαλίζοντας στατιστική εγκυρότητα.

Μοντέλο	Set	RMSE	MAE	MAPE	Max Error
Random Forest	Test	57,93	47,43	0,42	150,2
	Train	22,83	18,36	0,16	74,94
Gaussian Process	Test	54,72	44,51	0,39	136,15
	Train	51,75	41,74	0,37	153,28
SVR	Test	55,4	44,76	0,4	142,88
	Train	53,58	43,2	0,38	160,32
Gradient Boosting	Test	57,11	46,94	0,41	145,22
	Train	38,1	30,91	0,28	127,12

Πηγή δεδομένων: [diabetes_regression_full_results.numbers](#)

4.2 Συγκριτική Απεικόνιση (Excel Plot)

Για την εποπτική σύγκριση των μοντέλων, δημιουργήθηκε γραφική παράσταση (Εικόνα Β) που αποτυπώνει το μέσο τετραγωνικό σφάλμα (RMSE) στο Test set για κάθε αλγόριθμο.



Εικόνα Δ: Συγκριτικό διάγραμμα για τα τέσσερα μοντέλα.

Όπως φαίνεται στο διάγραμμα, το Gaussian Process σημειώνει τη χαμηλότερη μπάρα (χαμηλότερο σφάλμα), ενώ το Random Forest εμφανίζει τη χειρότερη επίδοση στο Test set, παρόλο που στο Train set είχε σχεδόν μηδενικό σφάλμα, επιβεβαιώνοντας οπτικά το συμπέρασμα περί overfitting.

4.3 Ερμηνεία Μετρήσεων & Συγκρίσεις

Το Gaussian Process πέτυχε το χαμηλότερο σφάλμα (RMSE: 54.72).


Παρατηρήθηκε σημαντικό φαινόμενο Overfitting στα δενδρικά μοντέλα. Για παράδειγμα, το Random Forest είχε εξαιρετικά χαμηλό σφάλμα στο Train set (RMSE ~22.83) αλλά υψηλό στο Test set (RMSE ~57.93). Αυτό εξηγείται από το μικρό μέγεθος του dataset, που επιτρέπει στα σύνθετα μοντέλα να "αποστηθίζουν" τα δεδομένα.

Το Gradient Boosting, παρόλο που εμφανίζει εξαιρετικά χαμηλό σφάλμα κατά την εκπαίδευση (Train RMSE: 38.1), στο Test set το σφάλμα του αυξάνεται στο 57.11. Αυτή η μεγάλη απόκλιση μεταξύ εκπαίδευσης και αξιολόγησης είναι σαφής ένδειξη overfitting (υπερπροσαρμογής).


Σε σύγκριση με τη βιβλιογραφία για το συγκεκριμένο dataset, όπου το RMSE κυμαίνεται στο 53-55, τα αποτελέσματά μας (54.72) κρίνονται απολύτως ικανοποιητικά και εντός του αποδεκτού ορίου $\pm 10\%$.

4.4 Γραφικές Παραστάσεις

Ακολουθεί το διάγραμμα Actual vs Predicted για το καλύτερο μοντέλο. Η εγγύτητα των σημείων στη διαγώνιο (ιδανική πρόβλεψη) επιβεβαιώνει την καλή προσαρμογή.




Εικόνα Β: Actual vs Predicted values για το μοντέλο Gaussian Process.



Εικόνα Γ: Actual vs predicted values για το μοντέλο Random Forest. Εδώ πετύχαμε το χειρότερο overfitting μοντέλο.

5. Ερμηνεία Μοντέλου (Explainability)


Για την ερμηνεία των προβλέψεων χρησιμοποιήθηκε η βιβλιοθήκη SHAP.



Εικόνα Ε: SHAP Summary Plot.

Τα χαρακτηριστικά bmi (Δείκτης Μάζας Σώματος) και s5 (Lamotrigine) βρίσκονται στην κορυφή, άρα έχουν τη μεγαλύτερη επίδραση στο μοντέλο.

Κατεύθυνση επίδρασης: Οι κόκκινες κουκκίδες (υψηλές τιμές χαρακτηριστικού) τείνουν να βρίσκονται δεξιά στον άξονα x (θετική τιμή SHAP). Αυτό σημαίνει ότι υψηλότερο BMI οδηγεί σε υψηλότερη πρόβλεψη για την εξέλιξη της νόσου, κάτι που είναι ιατρικά αναμενόμενο.



Εικόνα Z: Waterfall Plot

Στο συγκεκριμένο παράδειγμα, βλέπουμε πώς ξεκινώντας από τη μέση τιμή (Expected Value), η συνεισφορά κάθε χαρακτηριστικού (π.χ. +X λόγω ηλικίας, -Y λόγω χαμηλής πίεσης) διαμορφώνει την τελική πρόβλεψη.

6. Συμπεράσματα & Περιορισμοί

Τα Gaussian Processes και SVR αποδείχθηκαν οι καταλληλότεροι αλγόριθμοι για το συγκεκριμένο πρόβλημα, ξεπερνώντας τις πιο σύγχρονες μεθόδους (Gradient Boosting).

Το μικρό μέγεθος του dataset (442 εγγραφές) λειτούργησε αποτρεπτικά για τα Ensemble μοντέλα (Random Forest), τα οποία οδηγήθηκαν σε έντονο Overfitting, μαθαίνοντας θόρυβο αντί για πραγματικά μοτίβα.

Η ανάλυση SHAP επιβεβαίωσε ότι το μοντέλο έμαθε ουσιαστικές συσχετίσεις, αναγνωρίζοντας το BMI και τους δείκτες αίματος ως τους κρισιμότερους παράγοντες κινδύνου.

Τέλος, αξίζει να σημειωθεί ότι η σύγκριση των μοντέλων βασίστηκε στις μέσες τιμές των μετρικών από τα 6 folds. Αν και το Gaussian Process φαίνεται να υπερέχει αριθμητικά έναντι του SVR (54.72 έναντι 55.4), δεν πραγματοποιήθηκε στατιστικός έλεγχος σημαντικότητας (π.χ. paired t-test) για να επιβεβαιωθεί αν η διαφορά αυτή είναι στατιστικά σημαντική ή τυχαία. Επίσης, για λόγους διαχείρισης υπολογιστικών πόρων, η ανάλυση επεξηγηματικότητας (SHAP) παρουσιάστηκε αναλυτικά για το πρώτο fold της διαδικασίας validation. Μια μελλοντική επέκταση της εργασίας θα μπορούσε να περιλαμβάνει αυστηρούς στατιστικούς ελέγχους και συγκεντρωτική ανάλυση SHAP για όλα τα folds.

Περιορισμοί & Προτάσεις:

Το βασικό εμπόδιο της μελέτης ήταν ο μικρός αριθμός δεδομένων. Σε μελλοντική έρευνα, θα μπορούσαμε να επιλέξουμε εξ αρχής μόνο τα πιο σημαντικά χαρακτηριστικά (Feature Selection). Αυτό θα απλοποιούσε το πρόβλημα και θα βοηθούσε τα δενδρικά μοντέλα να πετύχουν καλύτερα αποτελέσματα.

7. Βιβλιογραφία

- Scikit-learn: Machine Learning in Python, Pedregosa et al., JMLR 12, pp. 2825-2830, 2011.
- Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. Advances in neural information processing systems, 30.
- Williams, C. K., & Rasmussen, C. E. (2006). Gaussian processes for machine learning. MIT press Cambridge, MA.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning: Data Mining, Inference, and Prediction. Springer.