

Πανεπιστήμιο Μακεδονίας - Τμήμα Εφαρμοσμένης Πληροφορικής

ΣΤΟΙΧΕΙΑ

Μάθημα: Μηχανική Μάθηση (Ζ' Εξάμηνο)

Ακαδημαϊκό έτος: 2025-2026

Τίτλος εργασίας: Πρόβλεψη Πτώχευσης Επιχειρήσεων με Χρήση Αλγορίθμων Μηχανικής Μάθησης (Classification)

Καθηγητής: Ευτύχιος Πρωτοπαπαδάκης

Ομάδα εργασίας:

1. Γουργιώτης Γεώργιος - ics23046

2. Όμηρος Λούπης - iis23088

Ημερομηνία: 12 Ιανουαρίου 2026

ΠΙΝΑΚΑΣ ΠΕΡΙΕΧΟΜΕΝΩΝ

1. Εισαγωγή
 - 1.1. Αντικείμενο και Στόχοι της Εργασίας
 - 1.2. Παρουσίαση του Προβλήματος της Πτώχευσης
2. Προτεινόμενη Μεθοδολογία
 - 2.1. Προεπεξεργασία Δεδομένων
 - 2.2. Σχήμα Αξιολόγησης
3. Πειραματικά Αποτελέσματα
 - 3.1. Περιγραφή του Dataset
 - 3.2. Μετρικές Αξιολόγησης Απόδοσης
 - 3.3. Συνολική Σύγκριση Μοντέλων
 - 3.4. Ανάλυση Σταθερότητας ανά Fold
 - 3.5. Έλεγχος Περιορισμών Απόδοσης
4. Συμπεράσματα
5. Βιβλιογραφία

ΚΑΤΑΛΟΓΟΣ ΕΙΚΟΝΩΝ

1. Εικόνα 1: Σύγκριση των μοντέλων με βάση το F1 – Score σε όλα τα Fold (Test set)
2. Εικόνα 2: Σύγκριση των μοντέλων με βάση το F1 – Score στο Fold 1 (Test set)
3. Εικόνα 3: Σύγκριση των μοντέλων με βάση το F1 – Score στο Fold 2 (Test set)
4. Εικόνα 4: Σύγκριση των μοντέλων με βάση το F1 – Score στο Fold 3 (Test set)
5. Εικόνα 5: Σύγκριση των μοντέλων με βάση το F1 – Score στο Fold 4 (Test set)
6. Εικόνα 6: Έλεγχος περιορισμών απόδοσης σε όλα τα Fold (Test set)
7. Εικόνα 7: Έλεγχος περιορισμών απόδοσης στο Fold 1 (Test set)
8. Εικόνα 8: Έλεγχος περιορισμών απόδοσης στο Fold 2 (Test set)
9. Εικόνα 9: Έλεγχος περιορισμών απόδοσης στο Fold 3 (Test set)
10. Εικόνα 10: Έλεγχος περιορισμών απόδοσης στο Fold 4 (Test set)

ΕΙΣΑΓΩΓΗ

1.1. ΑΝΤΙΚΕΙΜΕΝΟ ΚΑΙ ΣΤΟΧΟΙ ΤΗΣ ΕΡΓΑΣΙΑΣ

Αντικείμενο της παρούσας εργασίας αποτελεί η διερεύνηση και η συγκριτική αξιολόγηση αλγορίθμων Μηχανικής Μάθησης για την πρόβλεψη της πτώχευσης επιχειρήσεων. Στο πλαίσιο αυτό, χρησιμοποιήθηκε ένα dataset που περιλαμβάνει οικονομικούς δείκτες εταιρειών και εφαρμόστηκαν 8 διαφορετικοί αλγόριθμοι ταξινόμησης.

1.2. ΠΑΡΟΥΣΙΑΣΗ ΤΟΥ ΠΡΟΒΛΗΜΑΤΟΣ ΤΗΣ ΠΤΩΧΕΥΣΗΣ

Η πρόβλεψη της επιχειρηματικής αποτυχίας αποτελεί ένα κλασικό πρόβλημα δυαδικής ταξινόμησης (binary classification). Στην παρούσα ανάλυση, οι εταιρείες κατηγοριοποιούνται σε δύο διακριτές κλάσεις: στις “υγιείς” και σε εκείνες που βρίσκονται σε κατάσταση “πτώχευσης”. Η δυσκολία του προβλήματος έγκειται στην ασυμμετρία των δεδομένων, καθώς οι πτωχευμένες εταιρείες αποτελούν συνήθως ένα πολύ μικρό ποσοστό του συνολικού δείγματος.

ΠΡΟΤΕΙΝΟΜΕΝΗ ΜΕΘΟΔΟΛΟΓΙΑ

2.1. ΠΡΟΕΠΕΞΕΡΓΑΣΙΑ ΔΕΔΟΜΕΝΩΝ

Η προεπεξεργασία των δεδομένων αποτελεί το πρώτο και κρίσιμότερο στάδιο της ανάλυσης, καθώς διασφαλίζει ότι οι αλγόριθμοι θα λειτουργήσουν απρόσκοπτα και θα παράγουν αξιόπιστα αποτελέσματα. Οι βασικές ενέργειες που πραγματοποιήθηκαν είναι οι εξής:

1. **Διαχείριση Ελλειπουσών Τιμών (Missing Values):** Πριν απο οποιαδήποτε ανάλυση, πραγματοποιήθηκε έλεγχος για την ύπαρξη κενών ή μη έγκυρων τιμών στο σύνολο δεδομένων (dataset). Δεν παρουσιάστηκαν τέτοιες περιπτώσεις.

2. **Κανονικοποίηση (Normalization / Min-Max Scaling):** Εφαρμόστηκε η τεχνική της κανονικοποίησης ώστε όλες οι τιμές των χαρακτηριστικών να μετασχηματιστούν στο εύρος $[0,1]$. Η ενέργεια αυτή είναι επιβεβλημένη για τους εξής λόγους:
 1. Ισότιμη Συνεισφορά Χαρακτηριστικών: Αποτρέπει χαρακτηριστικά με μεγάλες αριθμητικές τιμές από το να κυριαρχούν έναντι άλλων με μικρότερες τιμές κατά την διάρκεια της εκπαίδευσης
 2. Βελτίωση Αλγορίθμων Βασισμένων σε Απόσταση: Διασφαλίζει ότι μοντέλα όπως ο k-NN (k – Nearest Neighbors) και ο SVM (Support Vector Machine), που υπολογίζουν αποστάσεις μεταξύ σημείων, δε θα επηρεαστούν από τις διαφορετικές κλίμακες των οικονομικών μεγεθών
 3. Ταχύτερη Σύγκλιση: Βοηθά τους αλγορίθμους βελτιστοποίησης να συγκλίνουν καλύτερα στην εύρεση των βέλτιστων παραμέτρων.

2.2 ΣΧΗΜΑ ΑΞΙΟΛΟΓΗΣΗΣ

Για την αντικειμενική αξιολόγηση της απόδοσης των αλγορίθμων και τη διασφάλιση της γενικευσιμότητας των αποτελεσμάτων σε νέα δεδομένα, υιοθετήθηκε η μέθοδος 4 – Fold Stratified Cross - Validation. Η επιλογή αυτή επιτρέπει την πλήρη αξιοποίηση του διαθέσιμου δείγματος, μειώνοντας την πιθανότητα μεροληψίας (bias) που θα μπορούσε να προκύψει από έναν τυχαίο διαχωρισμό. Η διαδικασία που ακολουθήθηκε περιγράφεται αναλυτικά παρακάτω:

- Διαχωρισμός Δεδομένων (train / test split): Το σύνολο των δεδομένων χωρίστηκε σε τέσσερα ίσα υποσύνολα. Σε κάθε μία από τις τέσσερις επαναλήψεις του πειράματος τα τρία υποσύνολα (**75%**) χρησιμοποιήθηκαν για την εκπαίδευση των μοντέλων, ενώ το εναπομείναν υποσύνολο (**25%**) λειτούργησε ως ανεξάρτητο σύνολο ελέγχου (test set).
- Αναπαραγωγικότητα: Προκειμένου η μελέτη να είναι πλήρως αναπαραγώγιμη από τον καθηγητή, χρησιμοποιήθηκε ένας ψευδοτυχαίος σπόρος (random_state = 42). Η παράμετρος αυτή “κλειδώνει” τη διαδικασία του διαχωρισμού των δεδομένων, εξασφαλίζοντας ότι κάθε εκτέλεση θα παράγει τα ίδια ακριβώς αποτελέσματα, όπως αυτά παρουσιάζονται στα διαγράμματα της αναφοράς.
- Όπως διαπιστώθηκε στην περιγραφή του dataset, η αναλογία μεταξύ υγιών και πτωχευμένων εταιρειών είναι εξαιρετικά ασύμμετρη. Προκειμένου να αποτραπεί η μεροληψία των μοντέλων υπέρ της πολυπληθέστερης κλάσης (υγιείς εταιρείες), εφαρμόστηκε η τεχνική τυχαίας δειγματοληψίας στο σύνολο εκπαίδευσης. Η τεχνική

αυτή εφαρμόστηκε αποκλειστικά στο σύνολο εκπαίδευσης (training set). Το σύνολο ελέγχου (test set) παρέμεινε ανέπαφο με την αρχική του κατανομή, ώστε η αξιολόγηση των μοντέλων να αντικατοπτρίζει τις πραγματικές συνθήκες.

3. ΠΕΙΡΑΜΑΤΙΚΑ ΑΠΟΤΕΛΕΣΜΑΤΑ

Στο κεφάλαιο αυτό παρουσιάζονται τα ευρήματα από τα πειράματα που διεξήχθησαν, ξεκινώντας από την ανάλυση των δεδομένων και καταλήγοντας στη σύγκριση των μοντέλων.

3.1. ΠΕΡΙΓΡΑΦΗ ΤΟΥ DATASET

Το σύνολο δεδομένων που χρησιμοποιήθηκε περιλαμβάνει δεδομένα από συνολικά 6819 εταιρείες. Στόχος είναι η πρόβλεψη της πτώχευσης με βάση διάφορους οικονομικούς δείκτες, οι οποίοι καλύπτουν διάφορες πτυχές της χρηματοοικονομικής κατάστασης μιας επιχείρησης.

Από την ανάλυση των δεδομένων προκύπτουν τα εξής στοιχεία:

- **Ασυμμετρία Κλάσεων:** Το dataset παρουσιάζει έντονη ανισορροπία, καθώς περίπου το 3% ανήκει στη κλάση της πτώχευσης, ενώ οι υπόλοιπες (περίπου το 97%) είναι υγιείς. Η ασυμμετρία αυτή καθιστά την απλή Ακρίβεια (Accuracy) μη αντιπροσωπευτική μετρική.
- Τα χαρακτηριστικά του dataset αποτελούν χρηματοοικονομικούς αριθμοδείκτες που προκύπτουν από την επεξεργασία των λογιστικών καταστάσεων των εταιρειών. Οι δείκτες αυτοί καλύπτουν κρίσιμους τομείς όπως η κερδοφορία, παρέχοντας στο μοντέλο μια πολυδιάστατη εικόνα της οικονομικής κατάστασης κάθε επιχείρησης.

3.2. ΜΕΤΡΙΚΕΣ ΑΞΙΟΛΟΓΗΣΗΣ ΑΠΟΔΟΣΗΣ


Υιοθετήθηκαν οι παρακάτω εξειδικευμένες μετρικές:

1. **Recall (Ανάκληση):** Μετράει το ποσοστό των εταιρειών που πραγματικά πτώχευσαν και εντοπίστηκαν σωστά από το μοντέλο
2. **True Negative Rate (Specificity / Εξειδίκευση):** Μετράει την ικανότητα του μοντέλου να αναγνωρίζει σωστά τις υγιείς εταιρείες.
3. **F1 – Score:** Αποτελεί τον αρμονικό μέσο της Ακρίβειας (Precision) και της Ανάκλησης (Recall). Χρησιμοποιείται ως η κύρια μετρική για την συνολική σύγκριση και κατάταξη των μοντέλων, καθώς παρέχει μια ισορροπημένη εικόνα της απόδοσης, ιδιαίτερα σε μη ισορροπημένα σύνολα δεδομένων.

Η επιλογή αυτών των μετρικών επιτρέπει την αξιολόγηση των μοντέλων όχι μόνο ως προς τη στατική τους ορθότητα, αλλά και ως προς την επιχειρησιακή τους χρησιμότητα βάσει των περιορισμών που τέθηκαν.

3.3 ΣΥΝΟΛΙΚΗ ΣΥΓΚΡΙΣΗ ΜΟΝΤΕΛΩΝ

Μετά την ολοκλήρωση της διαδικασίας της διασταυρωμένης επικύρωσης, υπολογίστηκε ο μέσος όρος του F1 – Score για κάθε αλγόριθμο στο σύνολο ελέγχου. Η συγκεκριμένη μετρική επιλέχθηκε για την τελική κατάταξη των μοντέλων καθώς αντικατοπτρίζει την ικανότητα τους να εξισορροπούν την ακρίβεια των προβλέψεων με την ευαισθησία στον εντοπισμό των πτωχεύσεων.




Εικόνα 1: Σύγκριση των μοντέλων με βάση το F1 – Score σε όλα τα Fold (Test set)

Όπως προκύπτει από τα συγκεντρωτικά αποτελέσματα, η κατάταξη των μοντέλων διαμορφώνεται ως εξής:

- **Βέλτιστο Μοντέλο:** Ο αλγόριθμος Random Forests πέτυχε την υψηλότερη επίδοση με μέσο F1 – Score = 0.21. Η υπεροχή του οφείλεται στην ικανότητα του να συνθέτει πολλαπλά δέντρα αποφάσεων, μειώνοντας τον κίνδυνο υπερπροσαρμογής (overfitting).
- **Ανταγωνιστικά Μοντέλα:** Πολύ κοντά στην κορυφή βρέθηκαν τα μοντέλα Support Vector Machine (SVM) με 0.20 και Gradient Boosting με 0.19. Ειδικά το SVM

έδειξε εξαιρετική σταθερότητα, επιβεβαιώνοντας ότι ο διαχωρισμός των κλάσεων στον πολυδιάστατο χώρο είναι εφικτός, έστω και με δυσκολία.


- Μοντέλα Χαμηλότερης Απόδοσης: Στις τελευταίες θέσεις βρέθηκαν οι αλγόριθμοι Decision Tree (0.11), Naive Bayes (0.15) και k-Nearest Neighbors (0.15). Το χαμηλό σκορ του Naive Bayes υποδηλώνει ότι η βασική του υπόθεση (ότι όλοι οι δείκτες είναι ανεξάρτητοι μεταξύ τους) δεν ισχύει στα οικονομικά δεδομένα.
- Ιδιαίτερη μνεία χρήζουν οι αλγόριθμοι Linear Discriminant Analysis (LDA) και Logistic Regression (LR). Παρόλο που πρόκειται για γραμμικά μοντέλα, επέδειξαν εξαιρετική ανθεκτικότητα και σε ορισμένες περιπτώσεις ξεπέρασαν ακόμη και τους πιο σύνθετους αλγορίθμους.



Εικόνα 2: Σύγκριση των μοντέλων με βάση το F1 – Score στο Fold 1 (Test set)

3.4. ΑΝΑΛΥΣΗ ΣΤΑΘΕΡΟΤΗΤΑΣ ΑΝΑ FOLD


Η εξέταση της μέσης απόδοσης από μόνη της δεν επαρκεί για την εξαγωγή ασφαλών συμπερασμάτων σχετικά με την αξιοπιστία των αλγορίθμων. Για τον λόγο αυτό, στις παρακάτω εικόνες παρουσιάζεται η διακύμανση του F1-Score για κάθε αλγόριθμο και στα τέσσερα folds της διαδικασίας Cross-Validation.



Εικόνα 3: Σύγκριση των Μοντέλων με Βάση το F1 – Score στο Fold 2 (Test Set)

Στο δεύτερο υποσύνολο ελέγχου (Fold 2), η κατάταξη των μοντέλων διαφοροποιείται σημαντικά, αναδεικνύοντας την ευαισθησία των αλγορίθμων στα συγκεκριμένα δεδομένα:


- **Κυριαρχία του SVM:** Το μοντέλο Support Vector Machine καταγράφει την κορυφαία επίδοση με F1-Score 0.27, επιβεβαιώνοντας ότι στο συγκεκριμένο δείγμα ο διαχωρισμός των κλάσεων στον υπερ-χώρο ήταν πιο ξεκάθαρος.
- **Ισχυρή Παρουσία Random Forests:** Ο αλγόριθμος Random Forests ακολουθεί σε απόσταση αναπνοής (0.26), αποδεικνύοντας τη σταθερότητά του ως ένα από τα πιο αξιόπιστα μοντέλα της μελέτης.
- **Σταθερότητα Γραμμικών Μοντέλων:** Τα LDA και Logistic Regression συνεχίζουν να αποδίδουν ικανοποιητικά, σημειώνοντας ισοπαλία με 0.23, γεγονός που ενισχύει την υπόθεση ότι υπάρχει σημαντική γραμμική πληροφορία στα δεδομένα.
- **Κατάρρευση του Decision Tree:** Στον αντίποδα, το Decision Tree σημειώνει τη χειρότερη επίδοση με μόλις 0.10. Αυτή η δραματική πτώση (σε σχέση με άλλα folds) είναι ενδεικτική της αστάθειας (high variance) που χαρακτηρίζει τα μεμονωμένα δέντρα αποφάσεων, τα οποία επηρεάζονται υπερβολικά από μικρές αλλαγές στα δεδομένα εκπαίδευσης.



Εικόνα 4: Σύγκριση των Μοντέλων με Βάση το F1 – Score στο Fold 3 (Test Set)

Στο τρίτο υποσύνολο ελέγχου (Fold 3), παρατηρείται μια καθολική πτώση της απόδοσης όλων των αλγορίθμων, γεγονός που υποδηλώνει ότι οι πτωχεύσεις που περιλαμβάνονταν σε αυτό το δείγμα ήταν δύσκολο να διαχωριστούν από τις υγιείς εταιρείες:

- **Ανθεκτικότητα του Random Forests:** Παρά τη γενική δυσκολία, το Random Forests αναδεικνύεται και πάλι νικητής με F1-Score 0.19. Είναι το μοναδικό μοντέλο που κατάφερε να πλησιάσει το 0,20, αποδεικνύοντας ότι η ensemble φύση του το καθιστά πιο ανθεκτικό σε "δύσκολα" δεδομένα σε σχέση με τους μεμονωμένους αλγορίθμους.
- **Πτώση των Γραμμικών Μοντέλων:** Σε αντίθεση με τα προηγούμενα folds όπου τα LDA και Logistic Regression πρωταγωνιστούσαν, εδώ περιορίζονται σε χαμηλές πτήσεις (0.14 και 0.12 αντίστοιχα). Αυτή η μεταβλητότητα επιβεβαιώνει ότι η γραμμική διαχωρισιμότητα δεν είναι χαρακτηριστικό ολόκληρου του dataset, αλλά μόνο συγκεκριμένων υποσυνόλων του.
- **Σταθερά Χαμηλές Επιδόσεις:** Οι αλγόριθμοι Decision Tree και k-NN παραμένουν καθηλωμένοι στο 0,10, επιβεβαιώνοντας την αδυναμία τους να γενικεύσουν σωστά σε αυτό το πρόβλημα.
- **Σύγκριση με Gradient Boosting:** Το Gradient Boosting διατηρείται στη δεύτερη θέση με 0.15, δείχνοντας ότι οι τεχνικές Boosting (όπως και το RF) έχουν μια σχετική υπεροχή έναντι των απλών μοντέλων όταν τα δεδομένα γίνονται πιο πολύπλοκα.




Εικόνα 5: Σύγκριση των Μοντέλων με Βάση το F1 – Score στο Fold 4 (Test set)

Στο τέταρτο και τελευταίο υποσύνολο ελέγχου (Fold 4), η εικόνα των αποτελεσμάτων διαφοροποιείται εκ νέου, αναδεικνύοντας τη δυναμική των αλγορίθμων ενίσχυσης (Boosting):

- Η Άνοδος του Gradient Boosting: Για πρώτη φορά στη διαδικασία, το Gradient Boosting κατακτά την πρωτιά με F1-Score 0,20. Αυτό υποδηλώνει ότι στο συγκεκριμένο τμήμα των δεδομένων, η σταδιακή διόρθωση των σφαλμάτων που εφαρμόζει ο αλγόριθμος (boosting) λειτούργησε αποτελεσματικότερα από τις άλλες μεθόδους.
- Η Σταθερή Αξία του Random Forests: Το Random Forests ακολουθεί σε απόσταση αναπνοής με 0,19. Η επίδοση αυτή είναι πανομοιότυπη με του Fold 3, επιβεβαιώνοντας για άλλη μια φορά ότι το Random Forests είναι ο πιο σταθερός αλγόριθμος (consistent), αποφεύγοντας τις μεγάλες διακυμάνσεις που εμφάνισαν οι ανταγωνιστές του στα διάφορα folds.
- Υποχώρηση SVM και Γραμμικών Μοντέλων: Το SVM (0,18) και τα γραμμικά μοντέλα (LR 0,16, LDA 0,15) κινούνται σε μέτρια επίπεδα, χωρίς να καταφέρουν να ξεχωρίσουν όπως έκαναν στα Fold 2 και 1 αντίστοιχα.
- Αδυναμία του Decision Tree: Το μεμονωμένο Decision Tree παραμένει ουραγός με 0,11, επιβεβαιώνοντας οριστικά ότι η χρήση ενός μόνο δέντρου δεν επαρκεί για την επίλυση του συγκεκριμένου προβλήματος πτώχευσης.

3.5. ΕΛΕΓΧΟΣ ΠΕΡΙΟΡΙΣΜΩΝ ΑΠΟΔΟΣΗΣ

Στην παρούσα ενότητα αξιολογείται η συμμόρφωση των αλγορίθμων με τους δύο επιχειρησιακούς περιορισμούς που τέθηκαν εξ αρχής ($\text{Recall} \geq 0.6$ και $\text{Specificity} \geq 0.7$), οι οποίοι κρίνονται απαραίτητοι για την πρακτική εφαρμογή του μοντέλου. Η ανάλυση βασίζεται στους μέσους όρους απόδοσης στο σύνολο ελέγχου (Test Set).



Εικόνα 6: Έλεγχος περιορισμών απόδοσης σε όλα τα Fold (Test set)

Με βάση τα ακριβή αριθμητικά δεδομένα που προκύπτουν από το διάγραμμα:

1. Περιορισμός (b) – Αναγνώριση Υγιών Εταιρειών ($\text{Specificity} \geq 0.7$):


Ο στόχος αυτός επιτυγχάνεται και υπερκαλύπτεται από όλους τους αλγορίθμους.

- Τα μοντέλα Logistic Regression και SVM σημειώνουν την υψηλότερη επίδοση με 0,94, προσφέροντας σχεδόν άριστη αναγνώριση των υγιών εταιρειών.
- Ακολουθούν το LDA (0,93) και το Random Forests (0,92).
- Ακόμη και το Decision Tree (DTC), που είχε τη χαμηλότερη επίδοση (0,83), βρίσκεται με ασφάλεια 13 μονάδες πάνω από το όριο.

Περιορισμός (α) – Εντοπισμός Πτωχεύσεων ($\text{Recall} \geq 0.6$):

Αντίθετα, κανένα μοντέλο δεν κατάφερε να προσεγγίσει το απαιτούμενο όριο.

- Την "καλύτερη" (συγκριτικά) επίδοση πέτυχε το Naïve Bayes (NB) με 0,51, το οποίο είναι και το μόνο που ξεπέρασε το 0,50.
- Το Gradient Boosting (GB) βρέθηκε ακριβώς στο 0,50 και το Random Forests (RF) στο 0,49.
- Ιδιαίτερη εντύπωση προκαλεί η επίδοση του Logistic Regression (LR): παρόλο που είχε την υψηλότερη Specificity (0,94), κατέγραψε τη χαμηλότερη Ανάκληση με μόλις 0,37, αποτυγχάνοντας πλήρως να εντοπίσει την πλειονότητα των πτωχεύσεων.




Εικόνα 7: Έλεγχος περιορισμών απόδοσης στο Fold 1 (Test set)

Η εξέταση των αποτελεσμάτων σε κάθε υποσύνολο (Fold) ξεχωριστά αποκαλύπτει κρίσιμες διαφοροποιήσεις στη συμπεριφορά των αλγορίθμων, οι οποίες χάνονται όταν εξετάζουμε μόνο τον γενικό μέσο όρο.

- Η Επιτυχία του Gradient Boosting: Ο αλγόριθμος Gradient Boosting πέτυχε Recall 0.60 και Specificity 0.90. Είναι η μοναδική περίπτωση στο Fold 1 όπου

ικανοποιήθηκαν ταυτόχρονα και οι δύο επιχειρησιακοί περιορισμοί ($\text{Recall} \geq 0.60$ και $\text{Specificity} \geq 0.70$).

- Επιθετικότητα του Decision Tree: Το Decision Tree πλησίασε επίσης τον στόχο με Recall 0.56, ωστόσο εμφάνισε τη χαμηλότερη Εξειδίκευση (0.82), δείχνοντας τάση για περισσότερα λάθη στους υγιείς (false positives).
- Συντηρητικά Μοντέλα: Αντίθετα, τα Logistic Regression και SVM παρέμειναν εξαιρετικά συντηρητικά, με πολύ υψηλή Εξειδίκευση (0.93) αλλά χαμηλή Ανάκληση (0.48 και 0.52 αντίστοιχα), αποτυγχάνοντας να εκμεταλλευτούν την ευκαιρία του δείγματος.




Εικόνα 8: Έλεγχος περιορισμών απόδοσης στο Fold 2 (Test set)

Το δεύτερο υποσύνολο ανέδειξε μια απροσδόκητη δυναμική, με τον αλγόριθμο Naïve Bayes να σημειώνει την πιο εντυπωσιακή επίδοση όλης της εργασίας ως προς την ευαισθησία.

- Υπέρβαση Ορίων: Ο Naïve Bayes πέτυχε Recall 0.69 και Specificity 0.87. Είναι η μοναδική περίπτωση όπου ένας αλγόριθμος ξεπέρασε το όριο του Recall (0.60) με τόσο μεγάλη διαφορά (+9 μονάδες), ικανοποιώντας ταυτόχρονα και τον περιορισμό της Εξειδίκευσης.

- Ο "Σχεδόν" Νικητής: Το Random Forests πλησίασε επίσης τον στόχο με Recall 0.58, διατηρώντας εξαιρετικά υψηλή Εξειδίκευση (0.93), επιβεβαιώνοντας τη σταθερή του ποιότητα.
- Ο Συντηρητισμός του SVM: Το SVM, παρόλο που πέτυχε την υψηλότερη Εξειδίκευση του πειράματος (0.96 – μόλις 4% λάθη στους υγιείς), έμεινε χαμηλά στο Recall (0.45), δείχνοντας αδυναμία να ρισκάρει για να βρει τις πτωχεύσεις.




Εικόνα 9: Έλεγχος περιορισμών απόδοσης στο Fold 3 (Test set)

Το τρίτο υποσύνολο δεδομένων αποδείχθηκε το πιο απαιτητικό σημείο της ανάλυσης, με όλα τα μοντέλα να αποτυγχάνουν παταγωδώς στον εντοπισμό των πτωχεύσεων.

- Κατάρρευση Ανάκλησης: Κανένα μοντέλο δεν πλησίασε καν το όριο του 0.60. Η υψηλότερη τιμή καταγράφηκε από το Random Forests με μόλις 0.40, απέχοντας 20 ολόκληρες μονάδες από τον στόχο.
- Υπερβολικός Συντηρητισμός: Τα μοντέλα επέδειξαν ακραία μεροληψία υπέρ των υγιών εταιρειών. Χαρακτηριστικά, το SVM και η Logistic Regression πέτυχαν σχεδόν τέλεια Εξειδίκευση (0.95 και 0.94 αντίστοιχα), αλλά «πλήρωσαν» αυτό το τμήμα με καταστροφικά χαμηλή Ανάκληση (0.24 και 0.23). Ουσιαστικά, τα μοντέλα αυτά προέβλεψαν σχεδόν όλες τις εταιρείες ως υγιείς.

- Η Σχετική Υπεροχή του RF: Παρόλο που απέτυχε στον στόχο, το Random Forests (0.40) ήταν το μόνο που διατήρησε μια αξιοπρεπή απόσταση από το μηδέν, σε αντίθεση με τα γραμμικά μοντέλα που κατέρρευσαν.



Εικόνα 10: Έλεγχος περιορισμών απόδοσης στο Fold 4 (Test set)

Στο τελευταίο υποσύνολο, παρατηρείται βελτίωση σε σχέση με το προηγούμενο fold, ωστόσο η "οροφή" του 60% παραμένει απροσπέλαστη.

- Η Συνέπεια του Naïve Bayes: Για άλλη μια φορά, το Naïve Bayes πλησίασε περισσότερο τον στόχο της Ανάκλησης με 0.52, αποδεικνύοντας ότι είναι το μοντέλο με τη μεγαλύτερη "προδιάθεση" να εντοπίζει πτωχεύσεις, έστω κι αν θυσιάζει λίγη Εξειδίκευση (0.88).
- Η Ισορροπία του Gradient Boosting: Το Gradient Boosting και το k-NN σταθεροποιήθηκαν στο 0.50 Recall. Ειδικά το Gradient Boosting συνδύασε αυτή την

επίδοση με πολύ υψηλή Εξειδίκευση (0.92), γεγονός που του χάρισε την πρωτιά στο F1-Score για αυτό το fold.

- Αποτυχία Γραμμικών Μοντέλων: Τα Logistic Regression (0.32), LDA (0.34) και SVM (0.39) παρέμειναν προσκολλημένα σε χαμηλές τιμές Ανάκλησης. Η επιμονή τους σε Εξειδίκευση άνω του 93% δείχνει ότι αδυνατούν να προσαρμοστούν όταν τα δεδομένα δεν είναι γραμμικά διαχωρίσιμα.

4. ΣΥΜΠΕΡΑΣΜΑΤΑ

Η παρούσα εργασία μελέτησε την εφαρμογή 8 αλγορίθμων Μηχανικής Μάθησης για την πρόβλεψη εταιρικών πτωχεύσεων, χρησιμοποιώντας ένα dataset χρηματοοικονομικών δεικτών. Μέσα από τη διαδικασία της προεπεξεργασίας και της αξιολόγησης με 4-fold Cross-Validation, προέκυψαν τα εξής σημαντικά συμπεράσματα:

Ως βέλτιστο μοντέλο για το συγκεκριμένο πρόβλημα προκρίνεται το **Random Forests**.

- Αιτιολόγηση: Παρόλο που σε μεμονωμένα folds ξεπεράστηκε από άλλους αλγορίθμους (όπως το Gradient Boosting στο Fold 4 ή το SVM στο Fold 2), το Random Forests επέδειξε την υψηλότερη σταθερότητα (robustness) και τον υψηλότερο μέσο όρο F1-Score (0,21).
- Συγκριτικό Πλεονέκτημα: Σε αντίθεση με τα Γραμμικά Μοντέλα (LR, LDA) που κατέρρευσαν στο Fold 3, και το Decision Tree που εμφάνισε μεγάλη διακύμανση, το Random Forests διατήρησε μια συνεπή συμπεριφορά, καθιστώντας το την ασφαλέστερη επιλογή για επιχειρησιακή χρήση.

Η ικανοποίηση των επιχειρησιακών στόχων ανέδειξε τη θεμελιώδη δυσκολία του προβλήματος:

- Επιτυχία στην Εξειδίκευση (Specificity $\geq 0,70$): Όλοι οι αλγόριθμοι υπερέκλυψαν τον στόχο, με το SVM και τη Logistic Regression να φτάνουν το 94%. Αυτό αποδεικνύει ότι τα μοντέλα μπορούν να αναγνωρίσουν με ασφάλεια τις υγιείς εταιρείες.
- Αστάθεια στην Ανάκληση (Recall $\geq 0,60$): Ο στόχος του εντοπισμού των πτωχεύσεων δεν επιτεύχθηκε στον γενικό μέσο όρο (Max Average: 0,51 από Naïve Bayes). Ωστόσο, η ανάλυση ανά Fold απέδειξε ότι ο στόχος είναι εφικτός:
 - a. Στο Fold 1, το Gradient Boosting πέτυχε Recall 0,60.

b. Στο Fold 2, ο Naïve Bayes πέτυχε το εντυπωσιακό Recall 0,69.

Η αποτυχία στον μέσο όρο οφείλεται στην πτώση της απόδοσης στα Folds 3 και 4, όπου τα χαρακτηριστικά των πτωχεύσεων ήταν λιγότερο διακριτά.

5. ΒΙΒΛΙΟΓΡΑΦΙΑ

1. Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
2. Cortes, C., & Vapnik, V. (1995). Support-Vector Networks. *Machine Learning*, 20(3), 273–297.
3. Friedman, J. H. (2001). Greedy Function Approximation: A Gradient Boosting Machine. *Annals of Statistics*, 29(5), 1189–1232.
4. Rish, I. (2001). An empirical study of the naive Bayes classifier. *IJCAI 2001 workshop on empirical methods in artificial intelligence*, 3(22), 41–46.
5. Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.